UNIVERSIDAD DE GRANADA

PRÁCTICA 3

Cloud Computing: Servicios y Aplicaciones

Alumna: Cristina del Águila Martín, cristinadam@correo.ugr.es

ÍNDICE

1. Configuración del entorno con Docker..... 3
    1.1. Fichero docker-compose.yaml..... 3
    1.2. Dockerfile..... 3
    1.3. Levantar los contenedores..... 3
    1.4. Acceso a los contenedores..... 3
2. Subida del dataset a HDFS..... 4
3. Clasificador con PySpark..... 4
4. Ejecución del script..... 7
5. Evaluación de los modelos y resultados obtenidos..... 7
7. Visualización..... 10
7. Problemas encontrados..... 12

Enlace al repositorio de GitHub con el código:
https://github.com/cristinadam1/CC-practica3

1. Configuración del entorno con Docker

Primero he creado mi estructura de carpetas con los siguientes comandos

```
mkdir practica3
cd practica3
mkdir spark
```

1.1. Fichero docker-compose.yaml

A continuación creo el archivo *docker-compose.yaml*, en el que voy a explicar cómo levantar varios contenedores y cómo se comunican entre ellos.
En este archivo defino lo siguiente:

- 1 contenedor NameNode (HDFS)
- 1 contenedor DataNode (HDFS)
- 1 contenedor Spark, con Python instalado

1.2. Dockerfile

A continuación creo el archivo Dockerfile en la carpeta `/spark (spark/Dockerfile)`, aquí le explico a Docker cómo construir el contenedor Spark con Python y las librerías que van a hacer falta.

1. Parto de una imagen con Spark ya instalado
2. Añado Python 3 y pip
3. Instalo numpy

1.3. Levantar los contenedores

Desde la carpeta practica3 utilizo el siguiente comando:

```
docker compose up -d
```

Lo cual va a levantar los siguientes contenedores:

- namenode: donde se gestiona el sistema de archivos HDFS
- datanode: almacén de los bloques de datos en el sistema HDFS
- spark: entorno para ejecutar tus scripts de análisis con PySpark

1.4. Acceso a los contenedores

Para conectarme al contenedor spark utilizo:

```
docker exec -it spark bash
```

Para conectarme al contenedor namenode utilizo:

```
docker exec -it namenode bash
```

2. Subida del dataset a HDFS

Descargo el dataset y lo copio en `~/data`

```
cp half_celestial.csv ~/data/
```

En el contenedor namenode hago lo siguiente:

```
hdfs dfs -mkdir -p /user/CCSA2425/cristinadam
hdfs dfs -put /data/half_celestial.csv /user/CCSA2425/cristinadam/
hdfs dfs -ls /user/CCSA2425/cristinadam
```

3. Clasificador con PySpark

En primer lugar, creo el archivo `clasificador.py`

1. Inicio la sesión de Spark

Ahora creo una sesión de Spark con el nombre "`Practica3-MLlib`", para usar las funcionalidades de procesamiento distribuido de PySpark. También uso la siguiente línea para reducir el nivel de los mensajes del sistema a solo errores para evitar información innecesaria durante la ejecución.

```
# 1. Crear sesión de Spark
spark = SparkSession.builder.appName("Practica3-MLlib").getOrCreate()
spark.sparkContext.setLogLevel("ERROR")
```

2. Carga del da

Leo el archivo CSV que había almacenado en HDFS, con cabecera y separación por punto y coma.

```
# 2. Cargar el dataset desde HDFS
path = "hdfs://namenode:8020/user/CCSA2425/cristinadam/half_celestial.csv"
df = spark.read.csv(path, header=True, inferSchema=True, sep=';')
```

3. Exploración inicial

Imprimo la estructura del DataFrame para conocer los tipos de cada columna. También calculo los valores nulos por columna y se enseño la distribución de clases (galaxy y star) en la variable objetivo.

```
# 3. Exploración de datos
print("\n Estructura del dataset:")
df.printSchema()

print("\n Valores nulos por columna:")
df.select([count(when(isnan(c) | col(c).isNull(), c)).alias(c) for c in df.columns]).show()

print("\n Distribución de clases:")
df.groupBy("type").count().show()
```

4. Preprocesamiento

Transformo la variable `type` a formato numérico con `StringIndexer`. Selecciono 10 variables numéricas como características, las agrupo en un único vector con `VectorAssembler (features_raw)`, y luego aplico un tipo de escalado según el modelo:

Para los modelos que toleran valores negativos (como regresión logística o Random Forest), aplico `StandardScaler`, que centra los datos en media cero y varianza uno. En cambio, para Naive Bayes (que exige entradas no negativas), uso `MinMaxScaler`, que transforma los datos al rango [0,1].

```
# 4. Preprocesamiento
# Convertir la variable de salida (galaxy/star) a numérica
indexer = StringIndexer(inputCol="type", outputCol="label")

# Columnas numéricas que uso como features
features = [
    "expAB_z", "i", "q_r", "modelFlux_r", "expAB_i",
    "expRad_u", "q_g", "psfMag_z", "dec", "psfMag_r"
]

# Ensamblo y normalizo features
assembler = VectorAssembler(inputCols=features, outputCol="features_raw")
scaler = StandardScaler(inputCol="features_raw", outputCol="features")

# Pipeline para modelos que admiten negativos
pipeline_std = Pipeline(stages=[indexer, assembler, StandardScaler(inputCol="features_raw", outputCol="features")])
data_std = pipeline_std.fit(df).transform(df).select("features", "label")

# Pipeline para NaiveBayes: features no negativas
pipeline_minmax = Pipeline(stages=[indexer, assembler, MinMaxScaler(inputCol="features_raw", outputCol="features")])
data_minmax = pipeline_minmax.fit(df).transform(df).select("features", "label")
```

Así, genero dos conjuntos distintos: `data_std` para los dos modelos y `data_minmax` exclusivamente para Naive Bayes.

5. División del conjunto de datos

Divido los dos conjuntos (`data_std` y `data_minmax`) en entrenamiento (80%) y prueba (20%) como se indica en el guión de prácticas, usando una semilla fija para garantizar reproducibilidad.

```
# 5. Partición de datos
# Para modelos estándar
train_std, test_std = data_std.randomSplit([0.8, 0.2], seed=42)

# Para NaiveBayes
train_minmax, test_minmax = data_minmax.randomSplit([0.8, 0.2], seed=42)
```

6. Definición de modelos

Defino seis modelos en total, agrupados en tres técnicas distintas:

- Regresión logística con dos configuraciones distintas de regularización (regParam).
- Random Forest, variando el número de árboles y la profundidad máxima.
- Naive Bayes, con dos valores de suavizado (smoothing).

```
modelos = {
    "LogisticRegression_1": LogisticRegression(maxIter=10, regParam=0.01),
    "LogisticRegression_2": LogisticRegression(maxIter=20, regParam=0.1),
    "RandomForest_1": RandomForestClassifier(numTrees=10, maxDepth=5),
    "RandomForest_2": RandomForestClassifier(numTrees=30, maxDepth=10),
    "DecisionTree_1": DecisionTreeClassifier(maxDepth=20),
    "DecisionTree_2": DecisionTreeClassifier(maxDepth=10),
    "NaiveBayes_1": NaiveBayes(smoothing=1.0),
    "NaiveBayes_2": NaiveBayes(smoothing=0.5)
}
```

7. Entrenamiento y evaluación

Recorro cada modelo y lo entreno sobre el conjunto de datos correspondiente (train_std o train_minmax). Luego, calculo la métrica AUC sobre el conjunto de prueba.

```
# 7. Entrenamiento y evaluación
print("\n Resultados:")
for nombre, modelo in modelos.items():
    if "NaiveBayes" in nombre:
        m = modelo.fit(train_minmax)
        predicciones = m.transform(test_minmax)
    else:
        m = modelo.fit(train_std)
        predicciones = m.transform(test_std)

    auc = evaluator.evaluate(predicciones)
    print(f"{nombre}: AUC = {auc:.4f}")
```

8. Cierre de Spark

Cierro la sesión de Spark para liberar los recursos utilizados

```
spark.stop()
```

4. Ejecución del script

Como no quería tener que estar copiando el archivo "`clasificador.py`" cada vez que lo modificaba, he optado por montar mi carpeta en el contenedor.
Para esto hago lo siguiente:

1. En mi docker-compose.yaml añado la siguiente línea

```
volumes:
    - ./:/workspace
```

Esto hace que todo lo que tengo en `practica3/` (mi carpeta local) aparezca en el contenedor Spark como `/workspace`.

2. Reinicio los contenedores

```
docker compose down
docker compose up -d
```

Esto aplica los cambios del `docker-compose.yaml`

3. Ejecuto el script directamente desde la carpeta montada
Entro al contenedor Spark

```
docker exec -it spark bash
```

y ejecuto el script desde `/workspace`

De esta forma, cada vez que edite `clasificador.py` en mi máquina local, el contenedor verá los cambios automáticamente, sin necesidad de volver a copiarlo.

5. Evaluación de los modelos y resultados obtenidos

El conjunto de datos utilizado contiene 1.000.000 instancias, distribuidas casi perfectamente entre las dos clases objetivo: galaxias (500.002) y estrellas (499.998). Todas las variables numéricas están completas, sin presencia de valores nulos, lo que ha facilitado el preprocesamiento sin necesidad de imputaciones.

```
Distribución de clases:
+------+------+
|  type| count|
+------+------+
|galaxy|500002|
|  star|499998|
+------+------+
```

Para abordar el problema de clasificación binaria, he usado 3 técnicas de construcción de clasificadores, probando 2 parametrizaciones de cada uno de los algoritmos. He usado como métrica principal el Área Bajo la Curva ROC (AUC), que permite comparar el rendimiento de los clasificadores teniendo en cuenta tanto la sensibilidad como la especificidad del modelo.

```
modelos = {
    "LogisticRegression_1": LogisticRegression(maxIter=10, regParam=0.01),
    "LogisticRegression_2": LogisticRegression(maxIter=20, regParam=0.1),
    "RandomForest_1": RandomForestClassifier(numTrees=10, maxDepth=5),
    "RandomForest_2": RandomForestClassifier(numTrees=30, maxDepth=10),
    "DecisionTree_1": DecisionTreeClassifier(maxDepth=20),
    "DecisionTree_2": DecisionTreeClassifier(maxDepth=10),
    "NaiveBayes_1": NaiveBayes(smoothing=1.0),
    "NaiveBayes_2": NaiveBayes(smoothing=0.5)
}
```

Los resultados obtenidos han los siguientes:

```
 Resultados:
LogisticRegression_1: AUC=0.8785, F1=0.8016, Precision=0.8044, Recall=0.8020
LogisticRegression_2: AUC=0.8372, F1=0.7613, Precision=0.7697, Recall=0.7628
RandomForest_1: AUC=0.9128, F1=0.8238, Precision=0.8313, Recall=0.8247
RandomForest_2: AUC=0.9686, F1=0.8960, Precision=0.8967, Recall=0.8960
DecisionTree_1: AUC=0.9385, F1=0.9053, Precision=0.9055, Recall=0.9053
DecisionTree_2: AUC=0.8684, F1=0.8843, Precision=0.8845, Recall=0.8843
NaiveBayes_1: AUC=0.6109, F1=0.6227, Precision=0.6251, Recall=0.6237
NaiveBayes_2: AUC=0.6109, F1=0.6227, Precision=0.6251, Recall=0.6237
```

Para la evaluación del rendimiento de los distintos modelos de clasificación desarrollados, como se observa en la imagen de arriba, he usado cuatro métricas estándar del aprendizaje automático: el área bajo la curva ROC (AUC), la puntuación F1, la precisión y la exhaustividad (recall). A continuación muestro los resultados obtenidos para cada modelo y cada parametrización en la siguiente tabla:

	AUC	**F1**	**Precision**	**Recall**
LogisticRegression_1 (maxIter=10, regParam=0.01)	0.8785	0.8016	0.8044	0.8020
LogisticRegression_2 (maxIter=20, regParam=0.1)	0.8372	0.7613	0.7697	0.7628
RandomForest_1 numTrees=10, maxDepth=5)	0.9128	0.8238	0.8313	0.8247

RandomForest_2 numTrees=30, maxDepth=10)	0.9686	0.8960	0.8967	0.8960
DecisionTree_1 (maxDepth=20)	0.9385	0.9053	0.9055	0.9053
DecisionTree_2 (maxDepth=10)	0.8684	0.8843	0.8845	0.8843
NaiveBayes_1 (smoothing=1.0)	0.6109	0.6227	0.6251	0.6237
NaiveBayes_2 (smoothing=0.5)	0.6109	0.6227	0.6251	0.6237

Tabla 1: Resultados obtenidos

Explicación de las métricas de evaluación:

- AUC (Área bajo la curva ROC): mide la capacidad del modelo para diferenciar entre las clases. Un valor cercano a 1 indica que el modelo clasifica bien los casos positivos y negativos. Si el valor se acerca a 0.5, el modelo no lo hace mejor que al azar
- Precisión: indica cuántos de los elementos que el modelo ha clasificado como positivos realmente lo son. Es útil cuando el coste de una predicción positiva incorrecta es alto
- Exhaustividad (Recall): mide cuántos de los elementos positivos reales ha conseguido detectar el modelo. Es especialmente importante cuando no se deben pasar por alto casos positivos
- F1-score: combina la precisión y la exhaustividad en una sola métrica. Calcula la media armónica de ambas. Sirve para evaluar el equilibrio entre detectar casos positivos y no cometer demasiados errores

Justificación de los parámetros usados en cada clasificador:

He probado diferentes configuraciones en cada clasificador para observar cómo afectan al rendimiento los cambios en los hiperparámetros.

- En *Regresión Logística*, he usado dos configuraciones. En la primera, he puesto `maxIter=10` y `regParam=0.01`, y en la segunda, `maxIter=20` y `regParam=0.1`. El número de iteraciones (maxIter) indica cuántos pasos realiza el algoritmo para encontrar los coeficientes óptimos. He aumentado este valor en la segunda configuración para ver si mejora la convergencia. El parámetro de regularización (regParam) sirve para evitar que el modelo se sobreentrene. He usado un valor mayor en la segunda configuración para aplicar más penalización y controlar mejor el ajuste

- En *Random Forest*, también he probado dos configuraciones. La primera tiene `numTrees=10` y `maxDepth=5`, y la segunda, `numTrees=30` y `maxDepth=10`. He aumentado el número de árboles y la profundidad para ver si el modelo mejora al captar patrones más complejos. He comprobado que al aumentar ambos valores, el modelo mejora notablemente en todas las métricas.

- En *Decision Tree*, he variado la profundidad del árbol: una configuración con `maxDepth=20` y otra con `maxDepth=10`. He querido comparar cómo afecta permitir una mayor profundidad frente a un árbol más simple. En este caso, el árbol más profundo ha conseguido mejores métricas, aunque la diferencia no es tan grande como en el caso de Random Forest.

- En *Naive Bayes*, he probado dos valores distintos para el parámetro `smoothing`: 1.0 y 0.5. Este parámetro evita errores cuando algún valor de entrada tiene probabilidad cero. Sin embargo, ambos modelos han dado exactamente los mismos resultados. Creo que esto ha sido porque el conjunto de datos está bien distribuido, no hay combinaciones con probabilidad cero, y el preprocesamiento con MinMaxScaler ha dejado los datos en un rango que no genera diferencias significativas al aplicar el suavizado. Por eso, cambiar el valor de smoothing no ha afectado al resultado final.

Conclusión obtenida:

Los modelos basados en árboles de decisión tienen un rendimiento claramente superior al resto de algoritmos que he evaluado. En particular, el modelo `DecisionTreeClassifier` con `maxDepth=20` ha sido el que ha tenido mejor rendimiento general, con una puntuación `F1` de 0.9053 y una `AUC` de 0.9385, lo cual indica un equilibrio bueno entre precisión y recall. Después, el modelo de Random Forest con 30 árboles (`numTrees=30`, `maxDepth=10`), que obtiene una `AUC` de 0.9686 y una `F1` de 0.8960.

Por otro lado, los modelos de Logistic Regression han teniendo resultados razonables, aunque más bajos que los de los modelos basados en árboles. El incremento del número de iteraciones y del parámetro de regularización ha supuesto una ligera pérdida.

El algoritmo de Naive Bayes ha sido el que ha dado peores resultados en todas las métricas, con una `AUC` de 0.6109 y una `F1` de 0.6227. Además este modelo ha necesitado un preprocesamiento distinto (escalado `MinMax`) por su necesidad de trabajar con valores que no fuesen negativos.

7. Visualización

Con los resultados obtenidos he usado una herramienta externa para visualizar los resultados en gráficas y que sean más interpretables, ya que con Spark no era posible generar gráficas directamente.

Esta primera gráfica nos sirve para comparar visualmente todas las métricas evaluadas en cada modelo. Al representar las métricas en una misma figura, se pueden identificar rápidamente qué modelos ofrecen un mejor equilibrio entre AUC, F1, Precisión y Recall. El resto son para ver cada métrica más detalladamente.

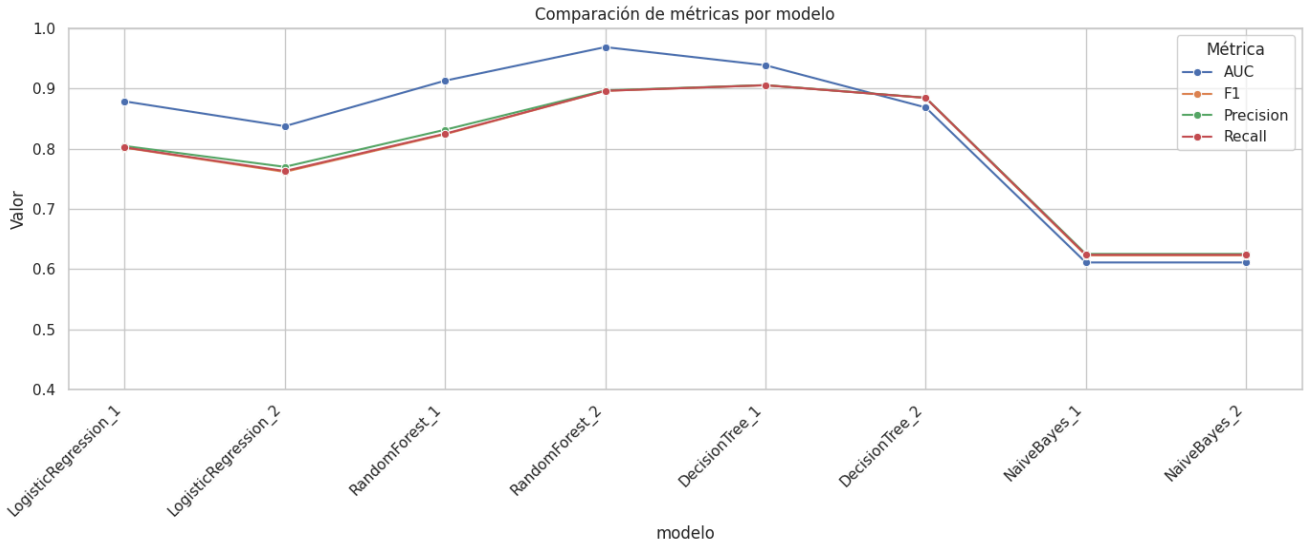
Comparación de métricas por modelo
Métrica
AUC
F1
Precision
Recall
Valor
1.0
0.9
0.8
0.7
0.6
0.5
0.4
LogisticRegression_1
LogisticRegression_2
RandomForest_1
RandomForest_2
DecisionTree_1
DecisionTree_2
NaiveBayes_1
NaiveBayes_2
modelo

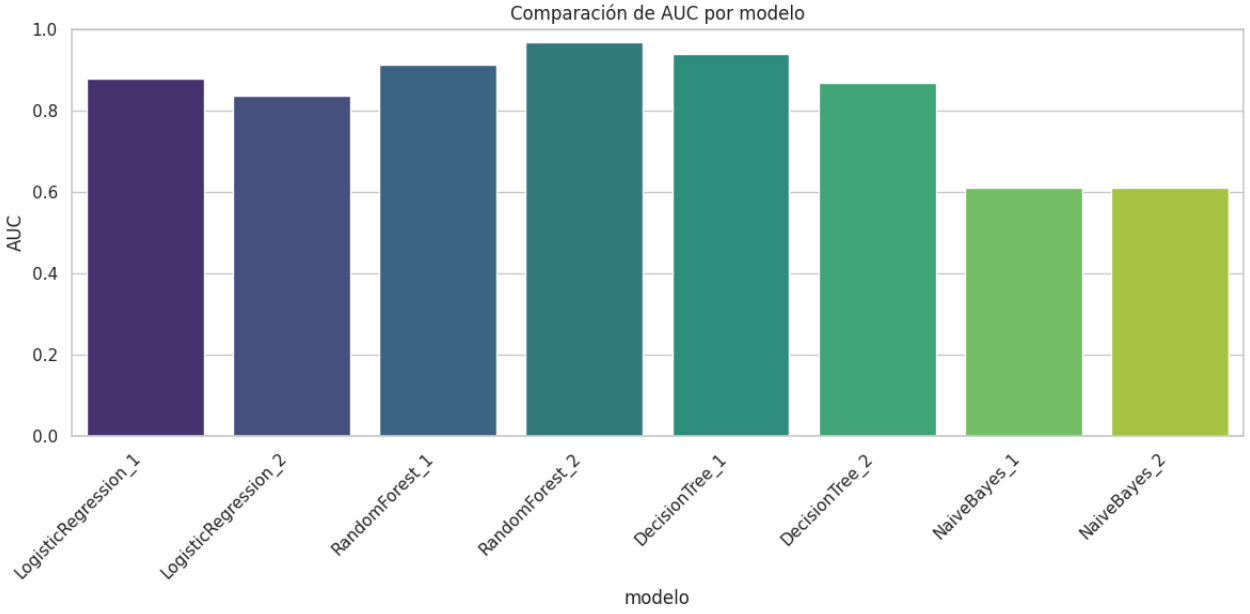
Comparación de AUC por modelo
AUC
1.0
0.8
0.6
0.4
0.2
0.0
LogisticRegression_1
LogisticRegression_2
RandomForest_1
RandomForest_2
DecisionTree_1
DecisionTree_2
NaiveBayes_1
NaiveBayes_2
modelo

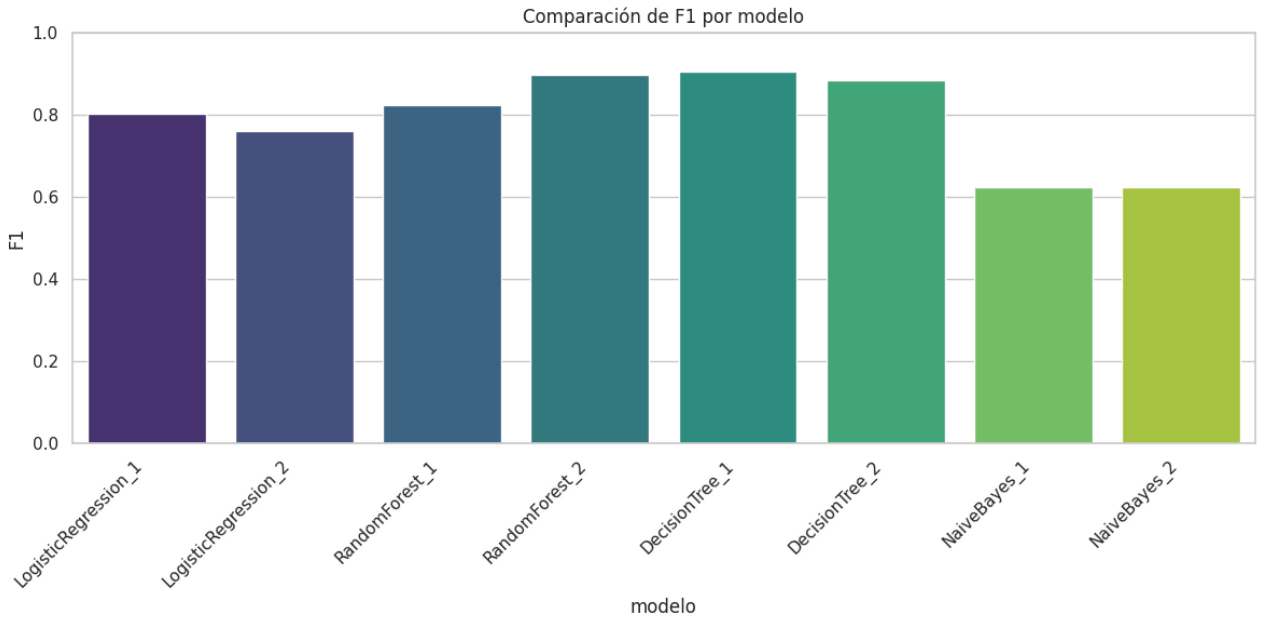
Comparación de F1 por modelo
F1
1.0
0.8
0.6
0.4
0.2
0.0
LogisticRegression_1
LogisticRegression_2
RandomForest_1
RandomForest_2
DecisionTree_1
DecisionTree_2
NaiveBayes_1
NaiveBayes_2
modelo

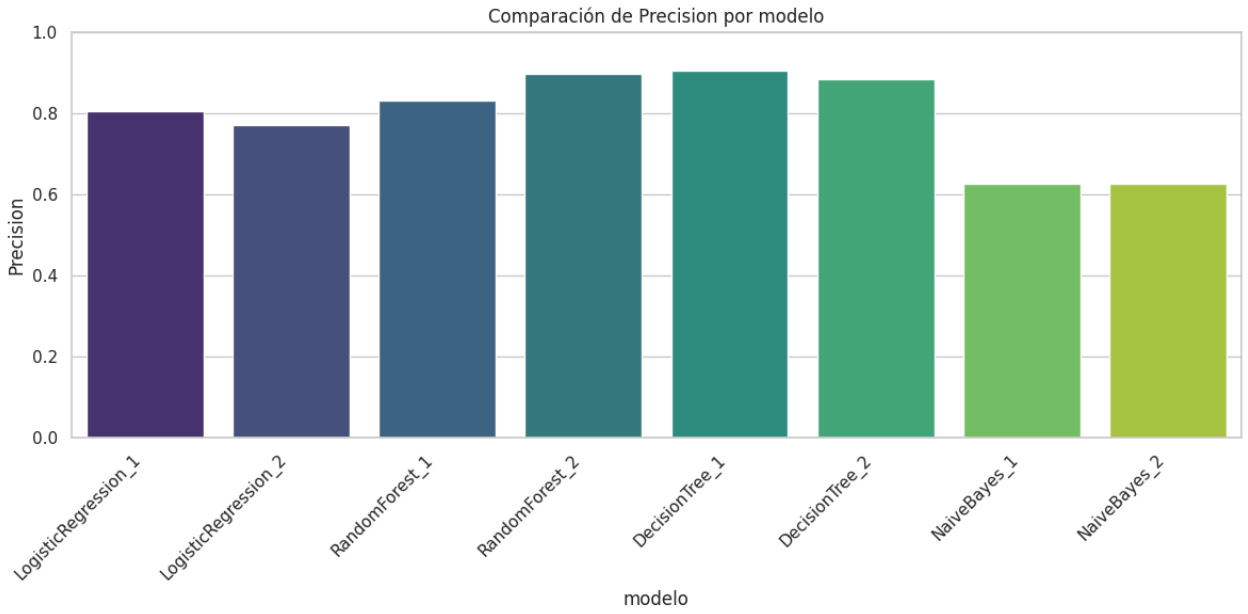

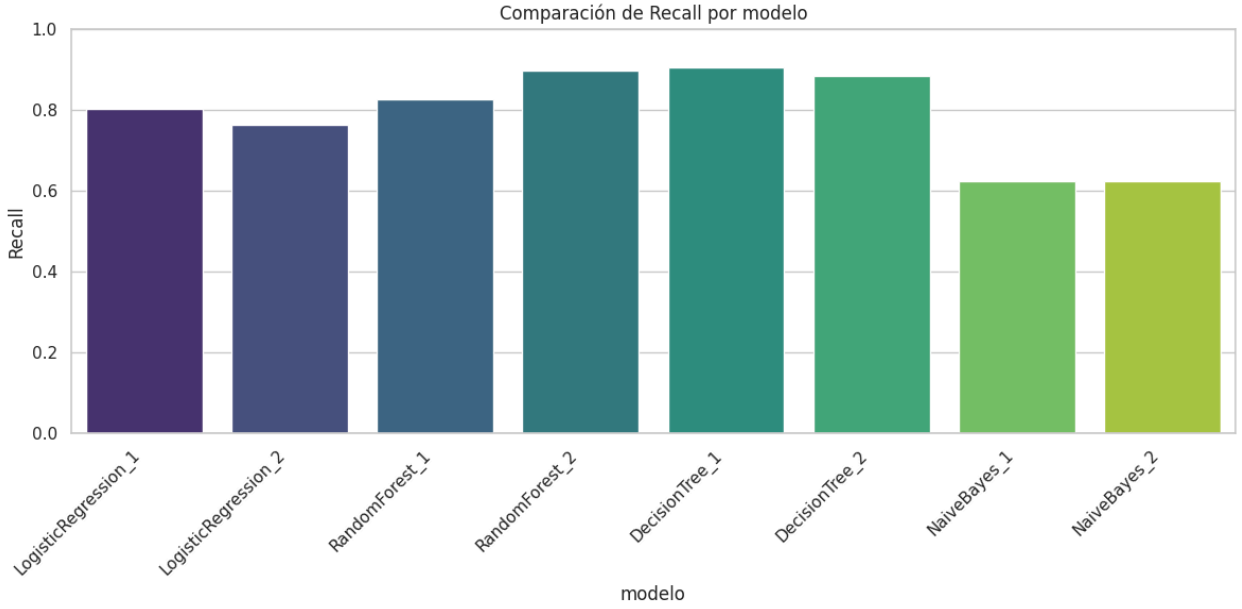

7. Problemas encontrados

Problema 1:

En el clasificador estaba obteniendo error por no separar bien las columanas. Para solucionarlo añado en la línea 15:

```
sep=';'
```

Problema 2:

No encontraba los errores porque me aparecía demasiada información en la terminal.

Para solucionarlo añado la siguiente línea de código a `clasificador.py` spark.

```
sparkContext.setLogLevel("ERROR")
```

Problema 3:

Al ejecutar el clasificador acababa en "Killed" esto era debido a que se estaba quedando sin memoria justo durante el entrenamiento de uno de los modelos.
Para solucionarlo ejecuto el clasificador con este comando:

```
spark-submit --master local[2] --executor-memory 4g
/workspace/clasificador.py
```

- `local[2]`: usa solo 2 núcleos (evita sobrecargar).
- `--executor-memory 4g`: da más RAM al proceso.

Además, también me he dado cuenta de que `RandomForest_2` (50 árboles, maxDepth=10) avanzaba bastante y casi terminaba, pero acababa fallando con el mensaje Killed, los mensajes indicaban un problema de recursos. Para solucionaro disminuyo el número de árboles a 30

Problema 4:

"requirement failed: Naive Bayes requires nonnegative feature values"

Este problema está relacionado con que el modelo Naive Bayes, exige que todas las features sean `>= 0`
En mi caso, esto aparecía porque estaba usando `StandardScaler` para todos los modelos.
Para solucionarlo, hago que NaiveBayes use `MinMaxScaler` en lugar de `StandardScaler,` mientras el resto de modelos (LogisticRegression y RandomForest) siguen usando `StandardScaler`